

Dans une architecture RAG (*Retrieval-Augmented Generation*), l'ingestion des données constitue la première étape critique pour enrichir le contexte d'un LLM avec des sources externes.

Le rôle des *loaders*

Les *document loaders* servent de passerelle entre les formats d'origine et le pipeline de traitement. Qu'il s'agisse de fichiers locaux (PDF, Markdown, CSV), de pages web ou de bases de données (Notion, SQL), le chargeur extrait le contenu brut, nettoie les données non pertinentes et standardise le flux entrant.

La structure de données d'un document

Une fois chargé, chaque fragment d'information est encapsulé dans un objet Document standardisé, composé de deux champs fondamentaux :

- **page_content (ou contenu textuel)** : la chaîne de texte brute qui sera vectorisée (*embedded*) puis insérée dans le prompt pour le modèle.
- **metadata (ou métadonnées)** : un dictionnaire clé-valeur stockant le contexte du fragment (source, titre, numéro de page, date, auteur ou identifiant unique).

Ces métadonnées sont essentielles en production : elles permettent d'appliquer des filtres avant ou après la recherche vectorielle (*self-querying*, filtrage par date ou permissions) et assurent la traçabilité des sources citées dans la réponse finale.